1 • 模型与量化

模型 BAAI **BGE-small-zh-v1.5**（MIT），浏览器 ONNX 版本来自 `Xenova/bge-small-zh-v1.5`，固定 revision `75c43b0`；BERT 4 层、hidden 512、max 512 tokens，CLS pooling + L2 normalize，查询侧加中文检索前缀。运行时 Transformers.js 3.8.1 + ONNX Runtime Web 1.22，推理全部在用户浏览器内完成。

精度	实测体积	压缩比	用途
FP32 基线	90.5 MiB	1×	质量对照
FP16	45.3 MiB	2.00×	WebGPU
INT8	22.9 MiB	3.95×	WASM

INT8 为 ONNX dynamic quantization：权重 8-bit、每通道 scale，激活运行时动态量化，无需校准集。同一 20 篇 / 20 分块 / 15 条标注查询、同一分块与查询前缀，仅替换精度的 dense 评测：

精度	Recall@5	nDCG@5	ΔnDCG
FP32	0.8333	0.8475	—
FP16	0.8333	0.8475	0.0000
INT8	0.8333	0.8504	+0.0029

Recall@5 不变，nDCG@5 变化 <0.3 个百分点；INT8 相对 FP32 的向量余弦保真度为 0.9830。小样本结论，详见 `evidence/quality-eval.json`。

2 • 端侧运行与自动降级

启动时 `navigator.gpu.requestAdapter()` 探测 WebGPU；可用则显式 `device:'webgpu', dtype:'fp16'`。适配器缺失、请求失败或 pipeline 初始化异常时，释放失败会话并重建 `device:'wasm', dtype:'q8'`，顶部同时显示“WASM·INT8 降级”和原因。模型从本地静态目录加载（`allowRemoteModels=false`），ORT jsep WASM 自托管，COOP/COEP 开启多线程。

> 验证：正常 Edge 自动选择 WebGPU·FP16；去掉 `navigator.gpu` 后自动降级，导入/检索/SQL trace 均正常。CSP `connect-src 'self'`，无任何云端推理 API。

3 • seekdb 数据层与混合检索

集合：每个知识库一个 `kb_<id>` collection。实测 DDL：

`_id varbinary(512) PK`、`document string`、`embedding VECTOR(512)`、`metadata json`；`FULLTEXT KEY idx_fts(document) WITH PARSER ik (ik_mode="smart")`；`VECTOR KEY idx_vec(embedding) WITH (DISTANCE=COSINE, TYPE=HNSW, M=16, EF_CONSTRUCTION=200, EF_SEARCH=64)`。

注册表：`stepkb_collections` 保存知识库名/描述/collection/计数；`stepkb_docs` 保存文档元数据与 content hash（去重）。

混合检索：一次 `collection.hybridSearch()` 调用，seekdb 的 `DBMS_HYBRID_SEARCH.GET_SQL` 生成并执行单条 SQL：`MATCH(document) AGAINST( … )` 做全文召回、`cosine_distance(embedding, … )` 做向量召回，FULL JOIN 后按 RRF `1/(60+keyword_rank)+1/(60+semantic_rank)` 排序。Node 服务不接收两路独立列表、不自行合并；响应中的 `hybridTrace.generatedSql` 即当次数据库生成的 SQL，界面可展开查看。

增量与刷新：单篇与批量写入 API；批量导入分块一次写入后整批只调一次 `refresh_index()`（`CALL dbms_index_manager.refresh()`），再登记为可检索。删除文档/知识库后刷新并清理注册表；切换知识库清空旧结果并按当前 collection 重新加载。

4 • 状态与性能优化

- active KB 存 localStorage，知识库/collection/计数以 seekdb 为准；文档 hash 去重。
- 约 360 字/块、重叠 60；16 条/批；批间让出主线程；模型常驻；模型/ORT wasm 强缓存。
- 冷/热、首次查询/后续查询、各阶段耗时全部写入可导出的性能面板。

批处理 WebGPU ×3.21 **32.3 → 103.7** 块/s	刷新合并 ×19.1 **12.5 → 0.66** s / 20 篇
热加载 WebGPU **1.32 → 0.88** s	热加载 WASM **1.00 → 0.78** s

5 • 实测性能

Windows 11 · Edge 156.0.4314.50 · Intel Core Ultra 7 155H / Arc Graphics · 31.5 GiB · seekdb 1.4.0 server（WSL2）。20 篇 / 20 分块 / 15 查询；每后端 3 轮新浏览器 context，热态 42 条查询取中位数。

指标	WebGPU·FP16	WASM·INT8
模型加载 / 预热	1,269 / 842 ms	1,032 / 65 ms
20 篇向量化	732 ms	2,197 ms
写入 + 刷新（刷新）	881（521）ms	761（516）ms
查询向量化	34 ms	31 ms
seekdb 检索	13 ms	8 ms
端到端（热 / 首）	83 / 439 ms	78 / 159 ms
Recall@5 / nDCG@5	0.867 / 0.879	0.900 / 0.895
Top-1 命中	45/45	45/45

WebGPU 对成批文档向量化明显更快（732 vs 2,197 ms），但单条查询的 GPU 提交/回读固定开销更高；应用仍按题目要求优先 WebGPU，并允许手动切换。降级验证：Recall@5 0.900 / nDCG@5 0.895，Top-1 15/15。原始数据见 `evidence/benchmark-summary.md`、`batch-bench-*.json`、`refresh-bench.json`、`load-bench.json`。

6 • 复现

`docker compose up -d`（或已有 seekdb 1.4 server）→ `pnpm install` → `pnpm fetch:models` → `pnpm prepare:assets` → `pnpm build && pnpm start`，打开 `http://127.0.0.1:8787`。测试：`pnpm test`、`STEPKB_INTEGRATION=1 pnpm test`；质量：`pnpm fetch:baseline && pnpm eval:quality`。模型/运行时/框架均公开可获取；模型清单与 SHA-256 见 `docs/model-manifest.json`。

> 端侧：embedding 在浏览器；数据层：seekdb 内完成向量/全文存储与 RRF 混合检索；没有回放服务端预计算，也没有调用云端推理。